

АО «Центральный научно-исследовательский центр
«Буревестник»»

Исследовательская работа

по теме: «Расчет параметров вычислительной среды для
корпоративной ИИ-ассистента в закрытом контуре»

ПРОВЕРИЛ:

_____ Гурьянов В.М.

ПОДГОТОВИЛ:

_____ Чаннов П.С.

Нижний Новгород

2026

Содержание

Оглавление

Содержание.....	1
Введение.....	2
Расчет вычислительных мощностей и проект архитектуры изолированной ИИ-системы для предприятия.....	3
Краткий ИИ-гlossарий	3
Расчет целевой производительности и профилей нагрузки вычислительной системы	4
Математический расчет требований к видеопамяти	7
Надежность ответов моделей и минимизация рисков галлюцинаций	9
Конфиденциальность данных и разграничение доступа в RAG-системе	12
Влияние требований безопасности и разграничения доступа на выбор оборудования	13
Архитектура изолированного оборонного контура (Air-Gap).....	14
Безопасность информации и соответствие стандартам ФСТЭК России	16
Технологический стек инференса и Специализированный конвейер	17
Специализированный конвейер обработки КД и чертежей	17
5-стороннее сравнение ИИ-ускорителей под требования закрытого предприятия	19
Экспертиза по альтернативным чипам и обоснование выбора.....	20
Три варианта конфигурации вычислительных мощностей	24
Вариант 1: на базе NVIDIA A40 PCIe.....	24
Вариант 2: на базе L40S	25
Вариант 3: на базе NVIDIA A100 PCIe	26
Финансово-экономическое сравнение вариантов (TCO)	28
Сценарий А: Раздельное развертывание (4 отдельных сервера)	28
Сценарий Б: Единая совмещенная ИИ-система (1 сервер).....	28
Итоговое заключение и рекомендации по выбору	31
Дополнительный раздел: Влияние расширения функционала RAG-моделями на требования к аппаратному обеспечению	32
Источники.....	33

Введение

Внедрение технологий генеративного искусственного интеллекта (ИИ) и больших языковых моделей (LLM/VLM) является ключевым фактором повышения производительности труда на современных предприятиях. Однако для организаций с закрытым контуром проектирования и жесткими требованиями к информационной безопасности (категория ДСП, коммерческая и служебная тайна) использование публичных облачных ИИ-сервисов полностью исключено. Единственным решением является развертывание суверенной, аппаратно изолированной ИИ-инфраструктуры внутри локальной сети предприятия.

Основная инженерная проблема при проектировании таких систем — высокая ресурсоемкость инференса (исполнения) тяжелых генеративных моделей. Избыточный заказ вычислительных мощностей ведет к неоправданному росту капитальных затрат (CAPEX), а недостаток ресурсов — к деградации качества обслуживания и срыву целевых показателей отказоустойчивости (SLA). В связи с этим критически важен точный предварительный расчет оборудования, учитывающий внутреннюю структуру организации и специфику задач сотрудников.

Расчет вычислительных мощностей и проект архитектуры изолированной ИИ-системы для предприятия

Краткий ИИ-гlossарий

Ниже приведены простые объяснения ключевых терминов, используемых в данном исследовании:

- **ИИ-ассистент (Языковая модель / LLM / ВЛМ):** Цифровой текстовый «мозг», обученный понимать человеческую речь, анализировать документы, делать логические выводы и писать ответы. Если модель умеет дополнительно обрабатывать конструкторскую документацию — ее называют мультимодальной (VLM).
- **Видеопамять (VRAM):** Сверхбыстрая память, находящаяся на специализированных ИИ-видеокартах (ускорителях). Это главный ресурс для ИИ: чем ее больше, тем более сложные модели мы можем запустить и тем больше сотрудников смогут работать с системой одновременно без задержек.
- **Оперативная память ИИ (KV-кэш):** Краткосрочная память ИИ, куда он записывает детали текущего диалога с сотрудником. Если этой памяти не хватает, ИИ начинает «забывать» начало разговора или медленно отвечать.
- **Сжатие моделей (Квантование):** Процесс оптимизации нейросети, позволяющий уменьшить размер ее весов в видеопамяти (VRAM, необходимой для размещения весов модели) в 2–4 раза практически без потери качества ответов. Позволяет экономить миллионы рублей на закупке серверов.
- **Метод «открытой книги» (RAG):** Технология работы ИИ с документами предприятия. Чтобы ИИ не выдумывал факты из головы, при каждом запросе система сначала автоматически ищет нужные ГОСТы, чертежи или первичные учетные документы во внутренней базе данных, а затем ИИ пишет точный ответ строго по найденным файлам.
- **Галлюцинации ИИ:** Ложные, выдуманные нейросетью факты, цифры или требования. В условиях закрытого предприятия этот показатель должен быть сведен к абсолютному минимуму.
- **Изолированный контур (Air-Gap):** Режим полной физической изоляции серверов ИИ от Интернета и внешних сетей. Гарантирует, что секретные данные предприятия никогда не покинут его пределы.
- **Локальные адаптеры (LoRA):** Небольшие программные «навыки» ИИ. Вместо покупки отдельных серверов под каждый отдел, мы устанавливаем одну базовую модель ИИ и динамически подключаем к ней легкие адаптеры (например, «для бухгалтерии» или «для конструкторского бюро»).

- **Интерконнект NVLink:** Высокоскоростная шина физического объединения нескольких видеокарт в один суперчип. В отличие от стандартной шины PCIe, она позволяет видеокартам обмениваться данными напрямую с пропускной способностью до 900 Гбайт/с, исключая задержки при работе с тяжелыми моделями.
- **Multi-Instance GPU (MIG):** Технология аппаратного разделения одной видеокарты на несколько полностью изолированных независимых ИИ-процессоров. Исключает взаимное влияние процессов и утечки данных между ними на физическом уровне.
- **Капитальные затраты (CAPEX):** Единовременные расходы предприятия на приобретение серверного оборудования, графических ускорителей и бессрочных лицензий на программное обеспечение.
- **Операционные затраты (OPEX):** Периодические (ежегодные) расходы на обеспечение функционирования системы, включающие затраты на электроэнергию, техническую поддержку, обновление подписок ИБ и оплату труда обслуживающего персонала.
- **Инференс (inference):** Это процесс использования уже обученной нейросети для решения задач в реальном времени.
- **Токен:** это минимальная единица текста, которую нейросеть (большая языковая модель) обрабатывает за один шаг.

Расчет целевой производительности и профилей нагрузки вычислительной системы

Для проектирования серверной инфраструктуры, обслуживающей 2000 пользователей в закрытом контуре предприятия, применяется методология статистического моделирования пиковых нагрузок. На основе структуры и потребностей предприятия выделяются **четыре группы пользователей** со специфическими требованиями к вычислительным ресурсам:

1. **Группа 1: Все пользователи (2000 человек) — Общий ассистент:** Решает повседневные задачи сотрудников, осуществляет быстрый поиск информации по общим регламентам предприятия, ГОСТам и нормативной базе. Среднее контекстное окно: 4096 токенов (базовые текстовые запросы).
2. **Группа 2: Конструкторский отдел (800 человек) — Инженерный ассистент:** Работа с конструкторской документацией (КД), чертежными листами, спецификациями и 3D-моделями деталей. Среднее контекстное окно: 8192 токена (обработка чертежей высокого разрешения и 3D-данных).
3. **Группа 3: Руководство (100 человек) — Аналитический ассистент:** Подготовка сводных отчетов, аналитика показателей, принятие стратегических решений с повышенным требованием к точности и скорости генерации. Среднее контекстное окно: 8192 токена.

4. **Группа 4: Административный отдел и другие службы (400 человек) — Специализированный ассистент:** Бухгалтерия, кадры, юристы (аудит больших договоров, финансовых ведомостей, бухгалтерских проводок). Среднее контекстное окно: 16\384 токена (удержание табличных данных большого объема в оперативной памяти ИИ).

При оценке пиковой конкурентности используется статистическая модель распределения Пуассона. Согласно нагрузкам предприятий, в пиковый час одновременно активны **до 30%** от общего числа пользователей.

- Для Группы 1 (Все пользователи): $2000 \times 0.30 = 600$ активных сотрудников.
- Для Группы 2 (Конструкторы): $800 \times 0.30 = 240$ активных сотрудников.
- Для Группы 3 (Руководство): $100 \times 0.30 = 30$ активных сотрудников.
- Для Группы 4 (Администраторы): $400 \times 0.30 = 120$ активных сотрудников.

Средний интервал между отправкой запросов у одного активного пользователя в пиковый период составляет 3 минуты (180 секунд). Среднее время обработки одного запроса на сервере (задержка prefill + decode) различается по группам из-за сложности задач:

- **Группа 1:** $T_{proc_all} = 3$ секунды (текст средней сложности).
- **Группа 2:** $T_{proc_cad} = 8$ секунд (из-за обработки графических файлов КД: двумерных растровых и векторных чертежей, схем сборки и трехмерных облаков точек деталей).
- **Группа 3:** $T_{proc_mng} = 4$ секунды (аналитика, высокая точность).
- **Группа 4:** $T_{proc_admin} = 5$ секунд (тяжелые таблицы, договоры).

Среднее число одновременно обрабатываемых запросов C_{avg} в системе определяется по закону Литтла отдельно для каждой группы:

- $\lambda_1 = \frac{600 \text{ пользователей}}{180 \text{ секунд}} \approx 3.33$ запросов в секунду
- $C_{avg_all} = \lambda_1 \times T_{proc_all} = 3.33 \times 3 \approx 10.0$ запросов
- $\lambda_2 = \frac{240 \text{ пользователей}}{180 \text{ секунд}} \approx 1.33$ запросов в секунду
- $C_{avg_cad} = \lambda_2 \times T_{proc_cad} = 1.33 \times 8 \approx 10.67$ запросов
- $\lambda_3 = \frac{30 \text{ пользователей}}{180 \text{ секунд}} \approx 0.167$ запросов в секунду
- $C_{avg_mng} = \lambda_3 \times T_{proc_mng} = 0.167 \times 4 \approx 0.67$ запросов
- $\lambda_4 = \frac{120 \text{ пользователей}}{180 \text{ секунд}} \approx 0.67$ запросов в секунду
- $C_{avg_admin} = \lambda_4 \times T_{proc_admin} = 0.67 \times 5 \approx 3.33$ запросов

Моделирование сценариев развертывания:

- **Сценарий А: Раздельное (изолированное) развертывание для отдельных групп.** Оборудование планируется точно под нужды конкретных отделов. Нагрузка рассчитывается по стандартному пику (SLA P95):
 - Только Группа 1: 30 конкурентных запросов.
 - Только Группа 2: 26 конкурентных запросов.
 - Только Группа 3: 4 конкурентных запроса.
 - Только Группа 4: 8 конкурентных запросов.
- **Сценарий Б: Единая совмещенная ИИ-система (2000 пользователей).** Все сервисы запущены на общем центральном кластере серверов:
 - Стандартный пик (SLA P95): $30 + 26 + 4 + 8 = 68$ одновременных запросов в секунду.
 - Экстремальный пик (SLA P99): $60 + 52 + 10 + 16 = 138$ одновременных запросов в секунду.

Параметр профилирования нагрузки	Группа 1 (Все пользователи)	Группа 2 (Конструкторы)	Группа 3 (Руководство)	Группа 4 (Администраторы)
Численность когорты пользователей	2000	800	100	400
Средний размер контекстного окна (токенов)	4096	8192	8192	16 384
Доля активных пользователей в пиковый час	30%	30%	30%	30%
Конкурентные запросы (Сценарий А: P95)	30	26	4	8
Конкурентные запросы (Сценарий Б: P99)	60	52	10	16

Параметр профилирования нагрузки	Группа 1 (Все пользователи)	Группа 2 (Конструкторы)	Группа 3 (Руководство)	Группа 4 (Администраторы)
Целевая скорость генерации на запрос (TPS)	40	40	40	40

Математический расчет требований к видеопамяти

Для обеспечения высокой точности выбраны модели ИИ с открытыми весами, прошедшие квантование до форматов FP8/INT8/INT4: Llama-3-8B-Instruct (для общих задач), Qwen2.5-VL-7B-Instruct / Qwen2.5-VL-72B-Instruct (для КБ), Qwen-2.5-32B-Instruct (для руководства и бухгалтерии).

Требуемый объем видеопамяти графического ускорителя M_{total} состоит из статической памяти для размещения весов модели $M_{weights}$ и динамической памяти для хранения контекста (кэша ключей и значений — M_{KV}).

Память весов рассчитывается по формуле:

$$M_{weights} = P \times Z \times 1.2 \text{ ГБ}$$

Где P — количество параметров модели в миллиардах, а Z — коэффициент квантования весов в байтах (FP16 = 2; FP8/INT8 = 1; INT4 = 0.5). Коэффициент 1.2 выражает эмпирический индустриальный стандарт **20% оверхеда** на накладные расходы по созданию CUDA-контекста, буферов активаций и системных процессов видеокарты.

Расчет динамического объема кэша ключей и значений (M_{KV}) для моделей с архитектурой Grouped-Query Attention (GQA) выполняется по следующей формуле:

$$M_{KV} = \frac{2 \times L \times H_{kv} \times D \times S \times B \times Z_{kv}}{10^9} \text{ ГБ}$$

Где:

- L — количество слоев декодера модели.
- H_{kv} — количество головок ключей и значений (KV-heads) в архитектуре GQA.
- D — размерность головки внимания (head dimension, для архитектур Qwen и Llama равная 128).
- S — длина контекстного окна (в токенах).
- B — размер батча (число параллельно обрабатываемых запросов).
- Z_{kv} — размер элемента кэша в байтах (FP16 = 2, FP8/INT8 = 1).

Результаты математического расчета потребности во VRAM для ключевых моделей при

новой структуре пиковой нагрузки (30% активности) представлены в таблице:

Идентифика- тор модели и формат весов	Статическая память весов $M_{weights}$, ГБ	Конкурентн ость (B)	Длина контекста (S)	Объем KV- кэша в FP16 $Z_{kv}=2$, ГБ	Объем KV- кэша в FP8 $Z_{kv}=1$, ГБ	Суммарная VRAM (кэш в FP8, ГБ)
Llama-3-8B- Instruct (FP8)	9.60	30	4096	16.11	8.05	17.65
Llama-3-8B- Instruct (FP8)	9.60	60	4096	32.22	16.11	25.71
Qwen-2.5- VL-7B- Instruct (FP16)	16.80	26	8192	27.91	13.96	30.76
Qwen-2.5- VL-7B- Instruct (FP16)	16.80	52	8192	55.82	27.91	44.71
Qwen-2.5- 32B-Instruct (INT8)	38.40	4	8192	8.59	4.30	42.70
Qwen-2.5- 32B-Instruct (INT8)	38.40	10	8192	21.48	10.74	49.14
Qwen-2.5- 32B-Instruct (INT8) — Админ.	38.40	8	16 384	34.36	17.18	55.58
Qwen-2.5- 32B-Instruct (INT8) — Админ.	38.40	16	16 384	68.72	34.36	72.76
Qwen2.5- VL-72B- Instruct	86.40	26	8192	80.53	40.27	126.67

Идентификатор модели и формат весов	Статическая память весов $M_{weights}$, ГБ	Конкурентность (B)	Длина контекста (S)	Объем KV-кэша в FP16 $Z_{kv}=2$, ГБ	Объем KV-кэша в FP8 $Z_{kv}=1$, ГБ	Суммарная VRAM (кэш в FP8, ГБ)
(INT8)						
Qwen2.5-VL-72B-Instruct (INT8)	86.40	52	8192	161.06	80.53	166.93

Надежность ответов моделей и минимизация рисков галлюцинаций

Особое внимание в условиях закрытого производства уделяется достоверности генерируемых ответов. Исследования показывают, что классические закрытые и открытые языковые модели при интеграции в поисковые контуры (RAG) без дополнительной оптимизации демонстрируют высокий уровень недостоверных фактов (галлюцинаций). Согласно результатам независимого исследования Stanford RegLab, даже коммерчески развернутые специализированные RAG-системы на базе ведущих мировых моделей демонстрируют долю галлюцинаций от 17% до 33%.

Для оборонного предприятия подобные показатели недопустимы, так как могут привести к ошибкам в финансовых ведомостях или искажениям на чертежах деталей и спецификациях. Для снижения вероятности галлюцинаций до минимально возможного уровня применяется комплекс архитектурных и алгоритмических решений:

- **Гибридный метод поиска (Hybrid Retrieval):** На этапе поиска контекста векторное сопоставление семантической близости комбинируется со статистическим поиском точных совпадений BM25. Это критично для извлечения документов, содержащих точные номера ГОСТов, шифры изделий, спецификации деталей и бухгалтерские проводки.
- **Использование моделей переранжирования (Re-Ranking):** Извлеченные на первом этапе 30–50 наиболее релевантных текстовых фрагментов (кандидатов) повторно оцениваются легковесной моделью кросс-кодировщика (Cross-Encoder), которая отбирает строго топ-5 наиболее контекстуально значимых фрагментов для передачи в LLM.
- **Контроль заземления (Contextual Grounding Checks):** В системный промпт модели встраиваются жесткие инструкции, запрещающие экстраполяцию данных. Модели предписывается отвечать исключительно на основе переданных фрагментов

документов, явно цитируя первоисточник и возвращая ответ «данные отсутствуют» при отсутствии информации в контексте.

- **Агентный парсинг таблиц (Agentic Table Parsing):** При анализе сложных финансовых отчетов и конструкторской документации текстовые блоки обрабатываются специализированными парсерами, преобразующими визуальные таблицы в структурированные JSON-объекты, что исключает ошибки пространственного распознавания ячеек языковой моделью.

Сравнительная эффективность методов борьбы с галлюцинациями представлена в следующей таблице:

Метод оптимизации контура RAG	Ожидаемое снижение уровня галлюцинаций	Накладные расходы на запрос	Влияние на время ответа (Latency)	Основная область применения
Базовый векторный поиск (Naïve RAG)	0% (Базовая линия — 17-33% ошибок)	Минимальные	Нет задержек	Простые текстовые запросы
Гибридный поиск (BM25 + Vector)	Снижение на 25–30%	Низкие	+10–20 мс	Поиск номенклатуры деталей, шифров КД
Двухэтапное переранжирование (Re-Ranking)	Снижение на 45–50%	Средние	+50–100 мс	Анализ регламентов, технологических карт
Контекстное заземление (Prompt Grounding)	Снижение на 60%	Минимальные	Минимальное	Финансовые расчеты, требования ИБ
Агентный RAG (с верификацией)	Снижение на 85–90%	Высокие	+500–1500 мс	Сверка чертежей, аудит ведомостей

Итоговый вывод по надежности ответов: Внедрение предложенного многоуровневого конвейера (гибридный поиск, переранжирование, жесткое контекстное заземление и агентный парсинг таблиц) позволяет подавить уровень галлюцинаций ИИ-ассистентов с базовых 17-33% до уровня менее 1.5–2%, что гарантирует соответствие системы строгим требованиям надежности и точности, предъявляемым на оборонном предприятии.

Влияние методов минимизации галлюцинаций на инфраструктуру и затраты: Внедрение многоуровневого конвейера RAG накладывает дополнительные требования к

вычислительной подсистеме. Использование двухэтапного переранжирования (Re-Ranking) увеличивает нагрузку на вычислительные ядра центрального процессора (CPU) хоста на этапе пост-обработки. Применение наиболее эффективного Агентного RAG с верификацией приводит к увеличению числа последовательных обращений к LLM в рамках одного пользовательского запроса, что повышает общую утилизацию видеопамати (VRAM) и требует резервирования вычислительной мощности GPU на уровне 10-15% для сохранения целевого TPS. С точки зрения затрат на ПО, агентский парсинг требует развертывания локальных OCR-сервисов и структурированных парсеров, что учтено в статье операционных расходов на поддержку ИБ и системного софта.

Конфиденциальность данных и разграничение доступа в RAG-системе

Внедрение ИИ-ассистентов в закрытом оборонном контуре требует исключения любых рисков несанкционированного доступа пользователей к документам более высокого уровня конфиденциальности. Фильтрация данных на уровне веб-интерфейса является критически уязвимой, так как при ее сбое модель может выдать секретную информацию в составе контекста. В связи с этим в системе реализуется принцип разграничения доступа к документам на этапе извлечения (Permission-Aware Retrieval) с использованием раннего связывания (early binding).

Механизм раннего связывания гарантирует, что фильтрация прав происходит непосредственно внутри поискового индекса векторной базы данных (Qdrant или Milvus) до запуска алгоритма поиска сходства векторов. В процессе наполнения базы данных RAG-системы каждому текстовому фрагменту (чанку) сопоставляются метаданные, содержащие список разрешенных идентификаторов пользователей или групп (POSIX-like ACL). При обработке запроса промежуточный сервис запрашивает у локальной службы каталогов LDAP/Active Directory текущие права доступа вошедшего пользователя. Полученный токен безопасности пользователя преобразуется в динамический строковый фильтр метаданных. Векторная база данных выполняет поиск исключительно по подмножеству документов, разрешенных данному пользователю, полностью исключая утечку защищаемой информации.

Сравнение подходов к разграничению прав доступа приведено в таблице:

Критерий сравнения	Раннее связывание (Early Binding) — Рекомендуется	Позднее связывание (Late Binding)	Фильтрация на уровне интерфейса (UI)
Место применения ограничений	Поисковый индекс СУБД	Пост-обработка результатов поиска	Клиентское приложение пользователя
Степень надежности	Нулевой риск утечки данных	Средняя степень (риск утечки через кэш)	Предельно высокая (модель знает все данные)
Влияние на качество поиска (Recall)	Оптимальное (поиск по валидному подмножеству)	Снижается (часть результатов отбрасывается)	Не влияет
Сложность синхронизации прав с LDAP	Высокая (требуется непрерывная синхронизация ACL)	Средняя	Низкая

Влияние требований безопасности и разграничения доступа на выбор оборудования

Требования информационной безопасности и разграничения доступа напрямую определяют минимальный объем системной памяти, процессорных ядер и выбор конкретных графических ускорителей:

- **Нагрузка на CPU и оперативную память хоста (RAM):** Механизм Permission-Aware Retrieval с ранним связыванием (early binding) требует постоянной синхронизации списков доступа (ACL) с локальным сервером Active Directory/LDAP. Сама векторная база данных (Qdrant/Milvus) при выполнении фильтрации прав доступа на лету перед векторным поиском создает дополнительную нагрузку на процессор. Для обеспечения низкого времени отклика при пиковой нагрузке требуется выделить не менее **4–8 выделенных высокочастотных ядер CPU** на сервер исключительно под задачи безопасности и фильтрации, а также зарезервировать не менее **32 ГБ системной RAM** под кэширование индексов прав доступа.
- **Оверхед средств защиты информации (СЗИ):** Использование сертифицированной ОС Astra Linux Special Edition со встроенными механизмами мандатного контроля целостности (МКЦ), замкнутой программной среды (ЗПС) и непрерывного аудита безопасности (логирования в SIEM) создает фоновый оверхед в размере **10–15% производительности центрального процессора (CPU)** и требует около **16–32 ГБ RAM**. Это учтено при выборе двухпроцессорных платформ с общим объемом оперативной памяти не менее 512 ГБ.
- **Влияние на выбор графических ускорителей (GPU):** Согласно требованиям ИБ, при обработке конфиденциальных данных разных подразделений (например, конструкторского бюро и бухгалтерии) недопустимо совместное использование физической видеопамяти и вычислительных ядер GPU без жесткой изоляции. Это делает невозможным использование обычных видеокарт (например, L40S) в рамках одного физического сервера без развертывания компенсирующих мер (программного разделения) или разделения на разные физические устройства. Напротив, выбор **NVIDIA A100** с технологией **MIG (Multi-Instance GPU)** позволяет аппаратно изолировать видеопамять и ядра на уровне чипа, разделяя одну физическую карту на 7 независимых изолированных зон. Это позволяет объединить все 4 группы пользователей на одном физическом сервере с соблюдением требований безопасности, экономя CAPEX на закупку дополнительных серверов.

Архитектура изолированного оборонного контура (Air-Gap)

Для предотвращения утечек информации на физическом уровне вся ИИ-система разворачивается в полностью изолированном сетевом контуре (air-gapped enclave), не имеющем физических и логических связей с внешними сетями общего пользования. Это накладывает жесткие требования на процессы поставки, обновления и функционирования программного обеспечения.

Все операции по импорту программных компонентов, библиотек и весов моделей выполняются по строго регламентированному двухзонному процессу:

- В «Грязной зоне» (подключенной к авторизованным репозиториям) на выделенной сборочной станции осуществляется загрузка базовых минимальных образов ОС (Astra Linux SE), компиляция всех необходимых Python-библиотек в локальные pre-compiled wheels и конвертация весов моделей в безопасный двоичный формат .safetensors, исключающий выполнение произвольного кода при инициализации. Сформированные OCI-образы контейнеров экспортируются в виде защищенных tar-архивов.
- Перенос архивов в «Чистую зону» оборонного завода осуществляется на физических носителях однократной записи (CD-R/DVD-R) или сертифицированных USB-накопителях, проходящих спецконтроль. В контуре «Чистой зоны» администратор безопасности выполняет верификацию цифровой подписи манифеста переноса с использованием локально предустановленного открытого ключа предприятия, а также осуществляет полный расчет контрольных сумм файлов по алгоритму ГОСТ Р 34.11-2012. При обнаружении малейшего расхождения хэшей импорт мгновенно блокируется.

Спецификация инфраструктурных сервисов изолированного контура приведена в следующей таблице:

Категория сервиса	Локальный компонент контура	Функция в изолированном анклаве	Отличие от облачной архитектуры
Реестр контейнеров	Harbor (локальное зеркало)	Хранение проверенных OCI-образов	Отсутствие связи с Docker Hub/NGC
Доменный доступ	Active Directory / LDAP	Аутентификация, мандатные уровни	Локальные списки отзывов сертификатов CRL
Векторная СУБД	Qdrant / Milvus (On-Prem)	Индексация документов RAG с ACL	Исключен сетевой API-доступ извне

Категория сервиса	Локальный компонент контура	Функция в изолированном анклаве	Отличие от облачной архитектуры
Мониторинг	Prometheus / Grafana	Отслеживание задержек и системных логов	Запрет на передачу внешней телеметрии
Документный парсинг	Apache Tika / Tesseract	Извлечение текста из сканов и PDF	Локальное выполнение без внешних API OCR

Безопасность информации и соответствие стандартам ФСТЭК России

Проектируемая система должна полностью соответствовать требованиям Третьего класса защищенности государственных информационных систем (ГИС) и Третьего уровня защищенности персональных данных (УЗ-3) согласно приказам ФСТЭК России. Данный уровень защищенности выбран на основе категории обрабатываемых данных: на предприятии система предназначена для обработки служебной конфиденциальной информации категории «Для служебного пользования» (ДСП), конструкторских документов и персональных данных сотрудников, без проведения работ со сведениями, составляющими государственную тайну. 3-й класс защиты является строго обязательным нормативным требованием ФСТЭК для ГИС такого масштаба, обеспечивающим защиту от угроз 3-го типа (связанных с недеklarированными возможностями в прикладном ПО).

Выполнение этих требований обеспечивается за счет интеграции встроенных сертифицированных механизмов защиты ОС Astra Linux Special Edition с прикладными средствами ИБ:

- **Мандатный контроль целостности (МКЦ):** Все процессы СУБД, веб-сервера и инференс-движка vLLM разделяются по иерархическим уровням целостности. Это предотвращает несанкционированную модификацию файлов моделей, системных логов и конфигураций со стороны вредоносного ПО.
- **Замкнутая программная среда (ЗПС):** ОС Astra Linux настраивается на запуск исключительно тех исполняемых файлов, которые подписаны доверенным ключом администратора безопасности предприятия. Это делает невозможным запуск несанкционированных скриптов, утилит обхода защиты или недоверенных контейнеров.
- **Контроль уязвимостей без сетевого доступа:** В изолированном контуре разворачивается локальный сканер безопасности, в состав которого интегрируется база данных уязвимостей ФСТЭК БДУ (содержащая более 74 000 записей о уязвимостях) и локальные OVAL-таблицы. Сканирование контейнеров и библиотек инференса производится в автономном режиме без обращений к внешним серверам.

Технологический стек инференса и Специализированный конвейер

Высокая плотность упаковки запросов и оптимальное использование дорогостоящей VRAM графических процессоров достигается за счет внедрения движка инференса vLLM и фреймворка S-LoRA. Применение наивного подхода к распределению памяти привело бы к частым сбоям по нехватке памяти (Out-Of-Memory — OOM) из-за непредсказуемого роста длины генерируемых токенов.

Технология PagedAttention в составе vLLM решает проблему фрагментации памяти за счет виртуализации кэша ключей и значений (KV Cache). Вместо выделения непрерывного блока памяти под максимальную длину контекста при старте запроса, vLLM выделяет память страницами фиксированного размера (по 16 токенов) динамически, по мере генерации. Это позволяет поднять коэффициент утилизации памяти ускорителя до 90–95%.

В условиях многозадачности оборонного завода, когда разным цехам требуются уникальные навыки, развертывание отдельных базовых моделей нецелесообразно. Вместо этого применяется архитектура S-LoRA. Базовая модель загружается в видеопамять один раз, а все специфические навыки выносятся в компактные LoRA-адаптеры, динамически подгружаемые в единый пул памяти.

Специализированный конвейер обработки КД и чертежей

Анализ чертежей и конструкторской документации (КД) представляет собой наиболее сложную вычислительную задачу в рамках данного проекта. Чертежи содержат высокую плотность геометрической и текстовой информации, которая при стандартном сжатии изображений для подачи в VLM полностью теряется. Для решения этой задачи в системе реализуется трехпроходный специализированный конвейер:

1. **Первый проход (Высокоразрешающая сегментация):** Исходный чертеж высокого разрешения не подается в VLM целиком. Локальный высокопроизводительный парсер анализирует изображение на субпиксельном уровне, локализует все размерные линии, стрелки, штампы основной надписи, текстовые выноски и спецификации деталей, формируя структурированный координатный атлас документа.
2. **Второй проход (Семантический синтез):** Мультимодальная модель Qwen2.5-VL-72B анализирует изображение, используя координатный атлас первого прохода в качестве семантических подсказок. Модель сопоставляет текстовые обозначения с конкретными деталями на чертеже.
3. **Третий проход (Генерация параметрического кода):** Модель CAD-Coder, прошедшая глубокое дообучение на специализированном датасете GenCAD-Code (содержащем свыше 163 000 пар изображений и кода), принимает на вход семантическую структуру чертежа и преобразует ее в исполняемый Python-код

формата CadQuery.

Разработанный конвейер на базе CAD-Coder и Qwen2.5-VL рассматривается как **перспективное экспериментальное научно-исследовательское направление (R&D) и пилотный проект**, а не как готовое к эксплуатации промышленное решение. В рамках текущего технологического уклада автоматическое восстановление полностью готовых 3D-моделей из чертежа без участия человека на промышленном уровне невозможно. ИИ-ассистент в данном случае выступает в роли помощника инженера: он анализирует двумерный чертежный лист и генерирует скрипты параметрического кода (CadQuery) или управляющую программу для ЧПУ (G-код). Инженер-конструктор вручную проверяет сгенерированный код, корректирует геометрические параметры и импортирует его в отечественную САПР (например, КОМПАС-3D) для построения 3D-модели детали. Для проведения объемного анализа и автоматического сопоставления деталей по форме применяется модель 3D-понимания PointVLM. Данная модель объединяет кодировщик облака точек (PointBERT) и визуально-языковой декодер Qwen2.5-VL, обеспечивая точную семантическую классификацию деталей непосредственно на основе трехмерных геометрических сканов и STEP-моделей.

5-стороннее сравнение ИИ-ускорителей под требования закрытого предприятия

Выбор графического процессора (GPU) для закрытого предприятия — это не только сравнение вычислительной скорости (TFLOPS), но и оценка технологической независимости, безопасности данных и совместимости с сертифицированным отечественным ПО.

Ниже приведена сравнительная таблица 5 ключевых ускорителей, подходящих для закрытого контура, на основе актуальной рыночной конъюнктуры 2025–2026 годов:

Модель GPU	Архитектура	Объем VRAM	Пропускная способность	NVLink	MIG	Энергопотребление	Стоимость (РФ)	Плюсы и минусы для предприятия
NVIDIA L40S	Ada Lovelace	48 ГБ GDDR6	864 ГБ/с	Нет	Нет	350 Вт	~900 000 руб.	(+) Высокий FP8-сырой compute, дешевизна. (-) Нет NVLink, отсутствие аппаратного MIG (требует дополнительных затрат на программные средства защиты и изоляции).
NVIDIA A100	Ampere	80 ГБ HBM2e	2.0 ТБ/с	Да (600 ГБ/с)	Да (7 зон)	400 Вт	~1 650 000 руб.	(+) Быстрая память, жесткая аппаратная изоляция MIG. (-) Высокая цена.

Модель GPU	Архитектура	Объем VRAM	Пропускная способность	NVLink	MIG	Энергопотребление	Стоимость (РФ)	Плюсы и минусы для предприятия
NVIDIA H100	Hopper	80 ГБ HBM3	3.35 ТБ/с	Да (900 ГБ/с)	Да (7 зон)	350-700 Вт	~3 300 000 руб.	(+) Экстремальный compute, FP8 Transformer. (-) Санкционные риски, цена.
NVIDIA A40	Ampere	48 ГБ GDDR6	696 ГБ/с	Да (112.5 ГБ/с)	Нет	300 Вт	~750 000 руб.	(+) Стабильность, NVLink, дешевизна. (-) Низкая скорость FP16, нет FP8.
AMD MI300X	CDNA 3	192 ГБ HBM3	5.3 ТБ/с	Да (Infinity Fabric)	Нет	750 Вт	~6 200 000 руб.	(+) 192 ГБ VRAM. (-) ROCm не сертифицирован ФСТЭК под Astra Linux SE.

Экспертиза по альтернативным чипам и обоснование выбора

В данном разделе представлена экспертиза ускорителей, вошедших в сравнительный анализ. В качестве целевых вариантов для детального проектирования архитектуры (Варианты 1, 2 и 3) были выбраны модели **NVIDIA A40, L40S и A100**, поскольку они обеспечивают полную совместимость со зрелым и стабильным программным стеком CUDA в условиях изолированного контура под управлением сертифицированной ОС Astra Linux Special Edition. Использование альтернативных решений на текущем этапе ограничено экономическими или инфраструктурными факторами:

1. **NVIDIA H100 80GB:** Обладает экстремальной скоростью благодаря сверхбыстрой памяти HBM3 (3.35 ТБ/с) и аппаратному движку Transformer Engine (нативная работа с FP8 без потери точности). Межчиповая шина NVLink 4.0 работает на рекордных 900 ГБ/с. Это идеальное решение для масштабных дата-центров, но для локального обслуживания 2000 пользователей в условиях предприятия оно является экономически избыточным.
2. **AMD Instinct MI300X 192GB:** Главная проблема — программная экосистема ROCm. В закрытом военном контуре, работающем под управлением защищенной ОС Astra Linux Special Edition, критически важна стабильность драйверов. Компиляция ROCm в изолированной «чистой зоне» Astra Linux без доступа к интернету — это крайне трудоемкий процесс с высокими рисками несовместимости. Продукт не сертифицирован отечественными регуляторами ИБ.
3. **NVIDIA A40 48GB:** Предыдущее поколение Ampere. Обладает пассивным серверным охлаждением, высокой отказоустойчивостью в режиме 24/7 и поддерживает NVLink средней скорости (112.5 ГБ/с). Превосходный бюджетный вариант для снижения капитальных затрат.

Представим на графиках разницу между моделями видеокарт:




Рис.1. Сравнение инференса видеокарт

На диаграмме приведены значения теоретической пиковой производительности для форматов FP16 и FP8 (для тех моделей, где аппаратная поддержка FP8 реализована на уровне тензорных ядер).

- NVIDIA A40 (48 ГБ, 300 Вт) – 150 TFLOPS в FP16, FP8 отсутствует. Уступает более современным решениям, однако остаётся самым доступным вариантом.
- NVIDIA L40S (48 ГБ, 350 Вт) – 366 TFLOPS в FP16 и 733 TFLOPS в FP8, что делает

его лидером среди рассматриваемых карт по производительности в 8-битных тензорах. Это критично для ускорения инференса LLM с квантованием весов.

- NVIDIA A100 (80 ГБ, 400 Вт) – максимальные 624 TFLOPS в FP16, но аппаратный FP8 не поддерживается. Карта обеспечивает высочайшую точность вычислений и подходит для обучения больших моделей, однако для задач инференса её производительность в FP8 уступает L40S.

● Производительность генерации: Llama-3-8B (FP8 / INT8)

Средняя скорость генерации (TPS) на одну видеокарту при пакетной обработке (Batch Size = 32)




Рис.2 производительность генерации Llama-3-8B (FP8 / INT8)

На диаграмме представлена средняя пропускная способность (токенов в секунду) на одну видеокарту при инференсе модели Llama-3-8B в форматах квантования, оптимальных для каждого ускорителя:

- NVIDIA L40S (FP8, 48 ГБ) – 420 токенов/с. Благодаря нативной поддержке FP8 в архитектуре Ada Lovelace и высокой тактовой частоте, L40S показывает максимальную производительность среди трёх вариантов.
- NVIDIA A100 (INT8, 80 ГБ) – 280 токенов/с. Карта имеет большую пропускную способность памяти и более мощные тензорные ядра, однако отсутствие аппаратного FP8 вынуждает использовать INT8, что даёт меньший прирост скорости.
- NVIDIA A40 (INT8, 48 ГБ) – 180 токенов/с. Наиболее доступный вариант, но уступает по сырой производительности из-за архитектуры Ampere и меньшей тактовой частоты.

Для задач, где критична высокая скорость генерации (чат-боты, быстрый поиск по документам), L40S является предпочтительным выбором. A100 и A40 могут использоваться при менее жёстких требованиях к латентности или в бюджетных сценариях.

● Тяжелые модели: Qwen2.5-VL-72B-Instruct (INT8)

Генерация параметрического кода (CadQuery) и распознавание КД. Требуется объединение VRAM нескольких карт.




Рис.3 Производительность генерации Qwen2.5-VL-72B (INT8) с объединением двух видеокарт

Модель Qwen2.5-VL-72B в формате INT8 занимает 86,4 ГБ статической памяти, что превышает объём VRAM одной карты (48 ГБ у L40S и A40, 80 ГБ у A100). Для её запуска требуется объединение двух видеокарт через Tensor Parallelism. Диаграмма показывает пропускную способность генерации при пакете из 16 параллельных запросов (Batch Size = 16):

- L40S (2x, PCIe Gen4) – 95 токенов/с. Обмен данными между картами происходит по шине PCIe (64 ГБ/с), что создаёт задержки при синхронизации слоёв.
- A40 (2x, NVLink 112.5 ГБ/с) – 70 токенов/с. Несмотря на наличие NVLink, его пропускная способность невысока, а сами карты имеют меньшую вычислительную мощность, что даёт самый низкий результат.
- A100 (2x, NVLink 600 ГБ/с) – 210 токенов/с. Высокоскоростной интерконнект и мощные тензорные ядра обеспечивают почти трёхкратное преимущество перед L40S. Это единственный вариант, позволяющий комфортно работать с большими VL-моделями в режиме реального времени.

Для задач, связанных с распознаванием чертежей, генерацией параметрического кода и анализом 3D-моделей (конструкторское бюро), использование A100 с NVLink является критически важным. L40S может быть приемлемым компромиссом для пилотных проектов, но при масштабировании нагрузки его производительность упадет. A40 в этом сценарии не рекомендуется из-за низкой скорости.

Три варианта конфигурации вычислительных мощностей

На основе структуры четырех подразделений предприятия (Группа общего ассистента — 2000 человек, Конструкторский отдел — 800 человек, Руководство — 100 человек, Административный отдел — 400 человек) разработаны три целевые конфигурации. Спецификация оборудования составлена с учетом возможности как совместной (централизованной) работы, так и отдельного развертывания под каждый отдел автономно в условиях **30% пиковой активности**.

Хранение корпоративных данных КД, чертежей, СУБД и смежные сервисы разворачиваются на изолированных серверных мощностях предприятия. В связи с этим локальная дисковая подсистема ИИ-серверов урезана и оптимизирована (применен отказоустойчивый RAID-1 зеркальный массив из 2 SSD) исключительно под задачи функционирования ОС, логов и локального кэширования весов ИИ-моделей.

Вариант 1: на базе NVIDIA A40 PCIe

Экономически выверенный вариант с фокусом на минимальный CAPEX при сохранении серверной надежности и аппаратного NVLink для разделения моделей.

- **Архитектурный подход при отдельной установке:**
 - Для **Общего ассистента (Группа 1)**: Требуется 1 сервер с 1 x NVIDIA A40 48GB. Модель Llama-3-8B (INT8) с батчем 30 займет всего 17.65 ГБ VRAM.
 - Для **КБ (Группа 2)**: Требуется 1 сервер с 2 x NVIDIA A40 48GB. Модель Qwen-2.5-VL-7B (INT8) весит 8.4 ГБ статической памяти, при пиковом батче 26 (30% активность) KV-кэш займет 13.96 ГБ, суммарно 22.36 ГБ на одну карту, что оставляет более 25 ГБ свободными.
 - Для **Руководства (Группа 3)**: Требуется 1 сервер с 1 x NVIDIA A40 48GB. Модель Qwen-2.5-32B (INT8) с батчем 4 занимает 42.70 ГБ VRAM, полностью укладываясь в лимит ускорителя (48 ГБ).
 - Для **Администраторов (Группа 4)**: Требуется 1 сервер с 2 x NVIDIA A40 48GB. Модель Qwen-2.5-32B (INT8) весит 38.4 ГБ, при батче 8 (30% активность) KV-кэш займет 17.18 ГБ. Итоговая нагрузка составляет **55.58 ГБ VRAM**, что делает необходимым параллельное развертывание на две видеокарты с объединением памяти через мост NVLink (Tensor Parallelism = 2).
- **Архитектурный подход при совмещенной (единой) установке:**
 - Все пользователи обслуживаются на одном сервере с 4 x NVIDIA A40 48GB.
 - GPU 0 выделяется под Группу 1 (Общий ассистент) и Группу 3 (Руководство).
 - GPU 1 выделяется под Группу 2 (Конструкторы).

- GPU 2 + GPU 3 (NVLink, TP=2) выделяются под Группу 4 (Администраторы).
- **Аппаратный состав ноды Варианта 1 (1 сервер 2U):**
 - **Процессоры:** 2 x Intel Xeon Silver (суммарно 32 ядра).
 - **Оперативная память:** 256 ГБ ECC DDR5.
 - **Накопители:** 2 x 960 ГБ SSD NVMe в RAID-1 (зеркало для ОС, логов и ИИ-моделей).
 - **Видеокарты:** 4 x NVIDIA A40 48GB (внешние мостики NVLink 112.5 ГБ/с).

Вариант 2: на базе L40S

Оптимальное сочетание высокой точности распознавания документов, чертежей и спецификаций со стабильностью работы системы при пиковых стандартных нагрузках (30% активность, SLA P95).

- **Архитектурный подход при раздельной установке:**
 - **Для Общего ассистента (Группа 1):** 1 сервер использует 1 x NVIDIA L40S 48GB. Модель Llama-3-8B FP8 (батч 30) требует 17.65 ГБ VRAM, обеспечивая максимальную скорость инференса.
 - **Для КБ (Группа 2):** 1 сервер с 2 x NVIDIA L40S 48GB. Модель Qwen-2.5-VL-7B разворачивается в чистом формате FP16 без сжатия (вес 16.80 ГБ). При батче 26 KV-кэш в FP8 займет 13.96 ГБ. Суммарная VRAM: **30.76 ГБ**, что гарантирует идеальную точность распознавания мелких чертежных линий.
 - **Для Руководства (Группа 3):** 1 сервер использует 1 x NVIDIA L40S 48GB. Модель Qwen-2.5-32B (INT8) при батче 4 занимает 42.70 ГБ VRAM, полностью укладываясь в лимит одной карты.
 - **Для Администраторов (Группа 4):** 1 сервер с 2 x NVIDIA L40S 48GB. Высокоточная модель Qwen-2.5-32B (INT8) требует **55.58 ГБ VRAM** при батче 8, что требует задействования двух карт L40S.
- **Архитектурный подход при совмещенной (единой) установке:**
 - Все четыре группы работают на одном сервере с 4 x NVIDIA L40S 48GB.
 - GPU 0: Группа 1 (Llama-3-8B FP8, VRAM при батче 30: 17.65 ГБ).
 - GPU 1: Группа 2 (Qwen-2.5-VL-7B FP16, VRAM при батче 26: 30.76 ГБ).
 - GPU 2 + GPU 3 (TP=2): Группа 3 и Группа 4 на базе модели Qwen-2.5-32B INT8.

- **Особенности обеспечения безопасности при совмещенной установке на L40S:**
Ввиду отсутствия технологии аппаратного разделения ресурсов на уровне MIG на картах NVIDIA L40S, разграничение прав доступа и изоляция контекстов Групп 1–4 реализуются на программном уровне с помощью средств мандатного контроля доступа ОС Astra Linux SE и контейнеризации. Возникающий при этом оверхед на CPU и требования к дополнительному программному слою защиты полностью компенсированы за счет выбора более производительной серверной платформы (Xeon Gold) и включения необходимых локальных лицензий СУБД и СЗИ в общую стоимость решения (CAPEX/OPEX первого года).
- **Аппаратный состав ноды Варианта 2 (1 сервер 2U):**
 - **Процессоры:** 2 x Intel Xeon Gold (суммарно 48 ядер).
 - **Оперативная память:** 512 ГБ ECC DDR5 (с запасом под кэширование СУБД и СЗИ).
 - **Накопители:** 2 x 960 ГБ SSD NVMe в RAID-1 (зеркало для ОС, логов и ИИ-моделей).
 - **Видеокарты:** 4 x NVIDIA L40S 48GB (подключение PCIe Gen4).

Вариант 3: на базе NVIDIA A100 PCIe

Максимально защищенное и отказоустойчивое решение оборонного уровня для работы со служебной конфиденциальной информацией категории ДСП в условиях повышенной 30% пиковой активности. Включает в себя тяжелые модели класса 72В параметров, технологию аппаратной изоляции MIG и интерконнект NVLink для исключения задержек при пиковой экстремальной нагрузке (SLA P99).

- **Архитектурный подход при отдельной установке:**
 - **Для Общего ассистента (Группа 1):** Требуется 1 сервер с 2 x NVIDIA A100 80GB PCIe. Модель Llama-3-8B FP8 при батче 30 занимает около 17.65 ГБ VRAM, обеспечивая огромный запас отказоустойчивости при пиковых нагрузках.
 - **Для КБ (Группа 2):** 1 сервер с 4 x NVIDIA A100 80GB PCIe. Сверхточная мультимодальная модель Qwen2.5-VL-72B (INT8) весит 86.4 ГБ статической памяти. При пиковой нагрузке в 26 одновременных запросов (P95) динамический KV-кэш потребует 40.27 ГБ. Итоговая потребность: **126.67 ГБ VRAM**, что распределяется по двум картам A100 с TP=2 через NVLink со скоростью 600 ГБ/с. При экстремальном пике в 52 запроса (P99) потребуются 166.93 ГБ VRAM.

- Для Администраторов и Руководства (Группы 3 и 4): 1 сервер с 2 x NVIDIA A100 80GB PCIe. Модель Qwen-2.5-72B INT8 с батчем 16 (P99) требует в сумме около **120.76 ГБ VRAM**, стабильно распределяясь по двум картам A100.
- **Архитектурный подход при совмещенной (единой) установке:**
 - Все группы работают на кластере из 2-х серверов (всего 8 x NVIDIA A100 80GB PCIe).
 - **Безопасность:** Благодаря технологии MIG одна физическая видеокарта A100 аппаратно нарезается на изолированные сегменты. Финансовая отчетность бухгалтерии, стратегическая аналитика руководства и закрытые конструкторские спецификации обрабатываются в физически отдельных ячейках памяти и на разных вычислительных ядрах, гарантируя нулевой риск утечки между подразделениями на физическом уровне.
- **Аппаратный состав кластера Варианта 3 (2 сервера 2U/4U):**
 - **Процессоры:** 4 x Intel Xeon Gold (по 2 процессора на сервер, 64 ядра на сервер).
 - **Оперативная память:** 1024 ГБ ECC DDR5 (по 512 ГБ на сервер).
 - **Накопители:** 4 x 1.92 ТБ SSD NVMe (по 2 SSD в RAID-1 на каждый сервер для ОС, логов и ИИ-моделей).
 - **Видеокарты:** 8 x NVIDIA A100 PCIe 80GB (объединенные мостиками NVLink 600 ГБ/с).

Финансово-экономическое сравнение вариантов (ТСО)

Расчет энергопотребления серверов выполнен с учетом средней загрузки и работы в круглосуточном режиме 24/7. Для расчета используется промышленный тариф Нижегородской области на уровне **6.19 руб. за кВт·ч** и коэффициент эффективности систем кондиционирования ЦОД (PUE) равный 1.5.

Поскольку раздельное и совмещенное развертывание требуют принципиально разного количества физических серверов и GPU, ниже представлен подробный расчет годовых затрат на электроэнергию (ЭЭ) для **обоих сценариев**:

Сценарий А: Раздельное развертывание (4 отдельных сервера)

Расчет: $((\text{База} \times N_{\text{серверов}}) + (\text{TDP_GPU} \times N_{\text{GPU}})) \times \text{PUE} \times \text{Часы} \times \text{Тариф}$

Вариант 1 (6 х A40):

- Серверы: 2 шт. по 1 GPU и 2 шт. по 2 GPU.
- Мощность: $(0.35 \times 4) + (0.3 \times 6) = 1.4 + 1.8 = 3.2$ кВт.
- Итого ЭЭ: $3.2 \text{ кВт} \times 1.5 \times 8760 \text{ ч} \times 6.19 \text{ руб.} \approx 260\,278 \text{ руб./год.}$

Вариант 2 (6 х L40S):

- Серверы: 2 шт. по 1 GPU и 2 шт. по 2 GPU.
- Мощность: $(0.35 \times 4) + (0.35 \times 6) = 1.4 + 2.1 = 3.5$ кВт.
- Итого ЭЭ: $3.5 \text{ кВт} \times 1.5 \times 8760 \text{ ч} \times 6.19 \text{ руб.} \approx 284\,679 \text{ руб./год.}$

Вариант 3 (8 х A100):

- Серверы: 2 шт. по 4 GPU.
- Мощность: $(0.35 \times 2) + (0.4 \times 8) = 0.7 + 3.2 = 3.9$ кВт.
- Итого ЭЭ: $4.0 \text{ кВт} \times 8760 \text{ ч} \times 1.5 \times 6.19 \text{ руб.} \approx 325\,346 \text{ руб./год.}$

Сценарий Б: Единая совмещенная ИИ-система (1 сервер)

Вариант 1 (1 сервер с 4 х A40):

- Мощность: $0.35 (\text{База}) + (0.3 \times 4) = 0.35 + 1.2 = 1.55$ кВт.
- Итого ЭЭ: $1.55 \text{ кВт} \times 1.5 \times 8760 \text{ ч} \times 6.19 \text{ руб.} \approx 126\,071 \text{ руб./год.}$

Вариант 2 (1 сервер с 4 х L40S):

- Мощность: $0.35 (\text{База}) + (0.35 \times 4) = 0.35 + 1.4 = 1.75$ кВт.

- Итого ЭЭ: $1.75 \text{ кВт} \times 1.5 \times 8760 \text{ ч} \times 6.19 \text{ руб.} \approx 142\,339 \text{ руб./год.}$

Вариант 3 (Кластер из 2 серверов с 8 х A100):

- (Примечание: для A100 сохраняется распределенная архитектура для обеспечения аппаратной изоляции MIG).
- Мощность: $(0.35 \times 2) + (0.4 \times 8) = 3.9 \text{ кВт.}$
- Итого ЭЭ: $: 2 \times 2.0 \text{ кВт} \times 8760 \text{ ч} \times 1.5 \times 6.19 \text{ руб.} \approx 325\,456 \text{ руб./год.}$

● Общие затраты первого года (ТСО), млн рублей




Рис.3 Сравнение ТСО первого года и затрат на электроэнергию в обоих сценариях

На диаграмме представлены полные затраты первого года (ТСО) и годовые расходы на электроэнергию для трёх вариантов GPU в двух сценариях развёртывания: раздельном (4 сервера) и совмещённом (1 сервер / кластер).

Ключевые цифры:

- Совмещённый сценарий даёт экономию в 2,3–2,4 раза по сравнению с раздельным для A40 и L40S. Для A100 экономия отсутствует, так как даже при совмещении требуется два сервера для аппаратной изоляции MIG.
- Разница между A40 и A100 в ТСО достигает 19 млн Р (в совмещённом сценарии), что делает A100 оправданным только при критических требованиях к безопасности и работе со сверхтяжёлыми моделями.
- Затраты на электроэнергию составляют не более 3,5% от ТСО и не являются определяющим фактором при выборе GPU.

Таким образом, L40S в совмещённой конфигурации – оптимальный баланс цены,

производительности и безопасности. А100 – только для задач, где обязательна аппаратная изоляция MIG. А40 – для пилотных проектов с минимальным CAPEX.

Статья расходов	Вариант 1: (на базе А40) Сценарий А (Раздельный)	Вариант 1: (на базе А40) Сценарий Б (Совмещенный)	Вариант 2: (на базе L40S) Сценарий А (Раздельный)	Вариант 2: (на базе L40S) Сценарий Б (Совмещенный)	Вариант 3: (на базе 8x А100)
Серверные платформы	5 200 000 руб. <i>(4 сервера 2U)</i>	1 300 000 руб. <i>(1 сервер 2U)</i>	9 000 000 руб. <i>(4 сервера 2U)</i>	2 250 000 руб. <i>(1 сервер 2U)</i>	6 500 000 руб. <i>(2 сервера)</i>
Графические ускорители	2 250 000 руб. <i>(6 x А40)</i>	1 500 000 руб. <i>(4 x А40)</i>	5 400 000 руб. <i>(6 x L40S)</i>	3 600 000 руб. <i>(4 x L40S)</i>	13 200 000 руб. <i>(8 x А100)</i>
Лицензии ОС Astra Linux SE	700 000 руб. <i>(4 шт.)</i>	175 000 руб. <i>(1 шт.)</i>	700 000 руб. <i>(4 шт.)</i>	175 000 руб. <i>(1 шт.)</i>	350 000 руб. <i>(2 шт.)</i>
Локальные лицензии СУБД	400 000 руб.	400 000 руб.	800 000 руб.	800 000 руб.	1 500 000 руб.
Энергопотребление (в год)	227 743 руб.	122 005 руб.	252 145 руб.	146 406 руб.	325 456 руб.
Обслуживание и ИБ (в год)	350 000 руб.	200 000 руб.	450 000 руб.	322 000 руб.	674 000 руб.
Итого затраты (ТСО первого года):	8 927 743 руб.	3 697 005 руб.	16 602 145 руб.	7 293 406 руб.	22 549 456 руб.

Итоговое заключение и рекомендации по выбору

- **Вариант 1 (на базе A40):** Показывает отличные финансовые результаты при совмещенной установке (3.7 млн руб.). Однако производительность карт поколения Ampere A40 в FP16 ограничена, а в условиях 30% пиковой активности малый объем памяти (48 ГБ) при раздельном сценарии потребует закупки 4 серверов, что поднимает ТСО до 8.9 млн рублей, лишая вариант его главного бюджетного преимущества.
- **Вариант 2 (на базе L40S):** Оптимален по соотношению цена/производительность для гражданских КБ при совмещенном подходе (Сценарий Б — ТСО 7.29 млн руб.). Попытка раздельного развертывания этого варианта ведет к росту ТСО до 16.6 млн рублей из-за закупки 4 серверных платформ и 6 дорогостоящих видеокарт. Программное компенсирование отсутствия MIG на L40S полностью учтено в Сценарии Б благодаря СЗИ под Astra Linux.
- **Вариант 3 (на базе A100 80GB):** Единственное рекомендуемое решение оборонного класса для закрытого предприятия.
 - **Безопасность данных категории ДСП:** Только технология MIG на картах A100 способна аппаратно разделить графический процессор на 7 независимых изолированных зон на физическом уровне, гарантируя выполнение требований ФСТЭК России.
 - **Уверенность при пиках нагрузки:** Объем памяти 80 ГБ HBM2e и пропускная способность шины NVLink (600 ГБ/с) полностью нивелируют риски падения скорости генерации или нехватки памяти при экстремальном росте конкурентных запросов до уровня 30% активности в пиковый час.

Дополнительный раздел: Влияние расширения функционала RAG-моделями на требования к аппаратному обеспечению

В случае, если LLM в процессе эксплуатации дополнительно наращивают RAG-моделями (Retrieval-Augmented Generation) для работы с локальной базой знаний, это существенно сказывается на требованиях к аппаратному обеспечению. Такое расширение функционала требует учета следующих инфраструктурных изменений:

1. **Многократный рост потребления видеопамати (VRAM):** В архитектуре RAG перед генерацией ответа нейросеть получает в изначальный запрос пользователя дополнительные документы (найденные регламенты, ГОСТы, чертежи), что значительно увеличивает длину входного контекста. В условиях 30% пиковой активности это приводит к критическому росту размера KV-кэша, требующего выделения дополнительных резервов видеопамати на ускорителях (GPU) для предотвращения ошибок Out-of-Memory.
2. **Развертывание моделей векторизации (Embeddings):** Для преобразования корпоративных документов в векторное представление и быстрого семантического поиска по ним требуется запуск отдельных моделей-эмбеддеров. Эти модели должны быть постоянно загружены в видеопамать (дополнительно 2–8 ГБ VRAM) и создают постоянную фоновую вычислительную нагрузку при индексации новых файлов.
3. **Нагрузка на серверную оперативную память (RAM) и накопители:** Индексация больших объемов конструкторской и административной документации требует развертывания специализированных векторных баз данных. Для обеспечения поиска без задержек векторные индексы кэшируются в оперативной памяти (DDR5) хоста, что диктует необходимость существенного расширения серверной RAM (вплоть до 512–1024 ГБ на узел).
4. **Увеличение задержки на переранжирование (Re-ranking):** Для обеспечения требуемой точности и исключения галлюцинаций в корпоративном RAG часто применяется этап переранжирования найденных фрагментов (Cross-Encoder). Это создает мощный вычислительный оверхед на ядра серверного процессора (CPU) или GPU, требуя более производительных чипов для недопущения роста времени обработки итогового ответа.

Источники

1. Siemens. Visual Language Models: Turning design chaos into order. The Art of the Possible. URL: <https://blogs.sw.siemens.com/art-of-the-possible/vlms-cad-order/>
2. Denneman, F. The Dynamic World of LLM Runtime Memory. 2026. URL: <https://frankdenneman.ai/2026-01-12-the-dynamic-world-of-llm-runtime-memory/>
3. Runpod. GPU Memory Sizing Guide for LLM Inference. URL: <https://www.runpod.io/articles/guides/gpu-memory-sizing-guide-for-llm-inference>
4. Spheron Network. KV Cache Optimization: Serve 10x More Users on the Same GPU. 2026. URL: <https://www.spheron.network/blog/kv-cache-optimization-guide/>
5. Onyx AI. Best Enterprise RAG Platforms for 2026: A Buyer's Guide. URL: <https://onyx.app/insights/enterprise-rag-platforms-2026>
6. Microsoft. Retrieval Augmented Generation (RAG) and Indexes in Microsoft Foundry. Microsoft Learn. URL: <https://learn.microsoft.com/en-us/azure/foundry/concepts/retrieval-augmented-generation>
7. Truefoundry. Air-Gapped AI: Deploying LLMs in Defense & Regulated Finance. URL: <https://www.truefoundry.com/blog/air-gapped-ai-deploying-enterprise-llms-in-highly-regulated-industries>
8. Zedly AI. On Premise LLM Deployment: The Complete Guide for Secure Enterprises. URL: <https://zedly.ai/blog/on-premise-llm-deployment>
9. Cambridge University, Department of Computer Science and Technology. S-LoRA: Serving Thousands of Concurrent LoRA Adapters. 2024–2025. URL: https://www.cl.cam.ac.uk/~ey204/teaching/ACS/R244_2024_2025/papers/SO-LORA_ARXIV_2024.pdf
10. Ranjan, M. Serving Thousands of Concurrent LoRA Adapters. Medium. 2024. URL: <https://medium.com/@mukulranjan/serving-thousands-of-concurrent-lora-adapters-6b407e8df516>
11. Spheron. NVIDIA L40S vs A100: Inference Throughput, VRAM, and Cost-Per-Token. 2026. URL: <https://www.spheron.network/blog/l40s-vs-a100/>
12. AceCloud. Why NVIDIA L40S Is Replacing A100 For AI Inference. URL: <https://acecloud.ai/blog/nvidia-l40s-vs-a100-ai-inference/>
13. Lenovo. LLM Sizing Guide. Lenovo Press. URL: <https://lenovopress.lenovo.com/lp2130.pdf>
14. onprem.ai. Transparently Calculate On-Premises AI Costs. URL: <https://www.onprem.ai/en/knowhow/llm-hardware-cost-calculator/>
15. aiLocallm. LLM GPU Sizing Guide: Estimate Users, Concurrency & Cost. URL: <https://ailocallm.com/gpu-sizing>
16. Kumar, D. The Truth About Production RAG Systems: It's Much More Than Retrieval + LLM. Medium. URL: https://medium.com/@diwakarkumar_18755/the-truth-about-production-rag-systems-its-much-more-than-retrieval-llm-eb786a068c47

17. Amazon Web Services. Document-Level Access Controls. Amazon Bedrock Documentation. URL: <https://docs.aws.amazon.com/bedrock/latest/userguide/kb-managed-ds-custom-acl.html>
18. Unstructured. From Technical Drawings to Queryable Engineering Data Using Unstructured. URL: <https://unstructured.io/blog/from-technical-drawings-to-queryable-engineering-data-using-unstructured>
19. Quarta Embedded. Astra Linux Special Edition и требования ФСТЭК № 117: защита информации. 2026. URL: <https://www.quarta-embedded.ru/news/news-10032026/>
20. Amazon Web Services. Secure Multi-Tenant RAG with Amazon Bedrock and Verified Permissions. AWS Architecture Blog. URL: <https://aws.amazon.com/blogs/architecture/secure-multi-tenant-rag-with-amazon-bedrock-and-verified-permissions/>
21. Microsoft. Document-Level Access Control. Azure AI Search Documentation. Microsoft Learn. URL: <https://learn.microsoft.com/en-us/azure/search/search-document-level-access-overview>
22. DiscreteStack. The Definitive Guide to Air-Gapped AI Deployment with No Internet in 2026. URL: <https://discretestack.com/blog/air-gapped-ai-deployment-no-internet-guide>
23. CIRCL. CVE-2023-52356. Vulnerability Lookup. URL: <https://cvepremium.circl.lu/vuln/cve-2023-52356>
24. NVIDIA. Air-Gap Deployment — NVIDIA NIM for Large Language Models. NVIDIA Documentation. URL: <https://docs.nvidia.com/nim/large-language-models/latest/deploy-air-gap.html>
25. OpenNix. SecureBaseline Cloud — CIS Scanning and Linux Hardening. OpenNix Documentation. URL: <https://opennix.org/en/docs/haas/>
26. TechPowerUp. News Posts Matching ‘Alibaba’. URL: <https://www.techpowerup.com/news-tags/Alibaba>
27. Massachusetts Institute of Technology. Vision-Language Models for Engineering Design: From Technical Documentation Benchmarking to CAD Generation. DSpace@MIT. URL: <https://dspace.mit.edu/entities/publication/ff7b3dee-88b0-4ecb-97fd-c0fa769e07f0>
28. American Society of Mechanical Engineers. CAD-Coder: An Open-Source Vision-Language Model for Computer-Aided Design Code Generation. IDETC-CIE Proceedings. ASME Digital Collection. URL: <https://asmedigitalcollection.asme.org/IDETC-CIE/proceedings/IDETC-CIE2025/89220/V03AT03A031/1225847>
29. arXiv. CAD-Coder: An Open-Source Vision-Language Model for Computer-Aided Design Code Generation. 2025. URL: <https://arxiv.org/html/2505.14646v1>
30. Autodesk Research. CadVLM: Bridging Language and Vision in the Generation of Parametric CAD Sketches. URL: <https://www.research.autodesk.com/publications/cad-vlm/>
31. OpenReview. PointVLM: Multi-Modal Vision-Language Model for CAD Model Understanding via Point Cloud Integration. URL: <https://openreview.net/forum?id=XroExfcQ5U>

32. ServerMall. Серверы для ИИ и нейросетей — купить мощный AI-сервер: цены. URL: <https://servermall.ru/sets/servery-dlya-ii/>
33. НИКС. Профессиональная видеокарта NVIDIA L40s. URL: https://www.nix.ru/autocatalog/svg_a_prof/Videokarta-900-2G133-0080-000-Nvidia-Tesla-L40s_797710.html
34. GPUYard. LLM Inference Benchmarks 2026: NVIDIA H100 vs L40S vs A100. URL: <https://www.gpuyard.com/blogs/llm-inference-benchmarks-h100-l40s-a100-roi/>
35. IntuitionLabs. NVIDIA Data Center GPU Specs: A Complete Comparison Guide. URL: <https://intuitionlabs.ai/articles/nvidia-data-center-gpu-specs>
36. Optcore. NVIDIA A100 vs H100 vs L40S vs A6000: A Detailed Comparison. URL: <https://www.optcore.net/nvidia-a100-vs-h100-vs-l40s-vs-a6000-comparison-w6/>
37. ServerMall. Серверы NVIDIA: купить, цены. URL: <https://servermall.ru/sets/servery-nvidia/>
38. AceCloud. How To Choose The Best GPU For AI Inference In 2025. URL: <https://acecloud.ai/blog/best-gpus-for-ai-inferencing/>
39. AITech.io. NVIDIA A100 vs H100 vs L40S: Which GPU Should You Rent? URL: <https://aitech.io/blogs/nvidia-a100-vs-h100-vs-l40s-which-gpu-should-you-rent-fa06e>
40. ServerMall. GPU NVIDIA A40 48 Gb: купить, цена. URL: <https://servermall.ru/catalog/videokarty/nvidia-a40-48gb/>
41. KNS. Фирменный магазин Nvidia — официальный дилер Нвидиа, интернет-магазин. URL: <https://www.kns.ru/shop/nvidia/>
42. Liquid Web. H100 vs A100 vs L40s [NVIDIA GPUs Side-by-Side]. URL: <https://www.liquidweb.com/gpu/a100-vs-h100-vs-l40s/>
43. Server ICT. Купить Серверы GPU Supermicro H100 Nvidia. URL: <https://serverict.com/servers-gpu/supermicro/supermicro-h100-nvidia/>
44. Linear. Details on the Design of 3D Pipelines (3D — Model Planning). Knowledge Base AutoCAD. URL: https://www.linear.eu/nl/services/knowledge-base-autocad/LS/V24/EN/AC/en/topics/neZe_r_befehlGrLeitungen3Dmodellplan_AC_neZe.html
45. GPUperHour. L40S vs A100: Inference vs Training Compared. URL: <https://gpuperhour.com/compare/l40s-vs-a100>
46. ServerFlow. Видеокарта NVIDIA H100 OEM 96 GB HBM3 [900-21010-0000-000]: купить в Москве, Санкт-Петербурге с доставкой по России. URL: <https://serverflow.ru/catalog/komplektuyushchie/videokarty/videokarta-nvidia-h100-oem-96gb-hbm3/>
47. Гарант. Тарифы на электроэнергию с 1 января собираются повысить на 1,7 % из-за роста НДС. URL: <https://www.garant.ru/news/1923487/>
48. Anyscale. Choose a GPU for LLM Serving. Anyscale Docs. URL: <https://docs.anyscale.com/llm/serving/gpu-guidance>